

Unidad 3: Introducción a Data Analytics

- 3.1. Data Analytics: Introducción
- 3.2 Evolución del proceso analítico
- 3.3 Estrategias de medición: KPIS, OKRs
- 3.4 Implementación: Fases
- 3.5 Data Manipulation, Data Visualization, Data Modeling
- 3.6 Casos de Estudio

3.1 DATA ANALYTICS

Se trata de un conjunto de técnicas y procesos cuantitativos y cualitativos usados para la toma de decisiones, con el objetivo de mejorar la productividad y las ganancias de un negocio a través del conocimiento extraído de los datos.

El estadístico John Tukey definió el análisis de datos en 1961 de esta manera:

"Son los procedimientos para analizar datos, las técnicas para interpretar los resultados de dichos procedimientos y las formas de planear la recolección de datos para hacer el análisis más fácil, más preciso o más exacto."

3.2 Evolución del proceso analítico

La evolución del proceso analítico ha sido significativa, marcada por avances tecnológicos y cambios en las metodologías utilizadas para extraer valor de los datos. A continuación, se describe cómo ha evolucionado este proceso a lo largo del tiempo:

➤ **Análisis Descriptivo**

- **Décadas de 1960 y 1970:** El análisis descriptivo fue uno de los primeros enfoques en el campo de la analítica de datos. Se centraba en describir y resumir datos históricos para entender qué había sucedido.
- **Herramientas:** Se utilizaban principalmente hojas de cálculo y sistemas de informes estáticos para resumir los datos. IBM desarrolló herramientas como los sistemas de gestión de bases de datos (DBMS) que permitieron a las empresas almacenar y recuperar grandes volúmenes de datos de manera más eficiente.

➤ **Análisis Diagnóstico**

Décadas de 1980 y 1990:

- **Propósito:** Este tipo de análisis busca entender las causas subyacentes de los eventos observados en el análisis descriptivo.

- **Enfoques:** Se implementaron técnicas estadísticas más avanzadas y herramientas de Business Intelligence (BI) para explorar los datos y descubrir relaciones y patrones.
- **Herramientas:** Herramientas como SAS y SPSS comenzaron a ganar popularidad, permitiendo análisis estadísticos más complejos y detallados.

➤ **Análisis Predictivo**

Década de 2000:

- **Propósito:** El análisis predictivo se enfoca en predecir futuros resultados basados en datos históricos y actuales. Utiliza técnicas de minería de datos, aprendizaje automático y modelos estadísticos.
- **Enfoques:** Algoritmos de machine learning y técnicas como regresión, árboles de decisión y redes neuronales se utilizan para construir modelos predictivos.
- **Herramientas:** Herramientas como R, Python (con bibliotecas como Scikit-learn y TensorFlow), y plataformas de big data como Hadoop y Spark permiten el procesamiento y análisis de grandes volúmenes de datos.

➤ **Análisis Prescriptivo**

Década de 2010:

- **Propósito:** Este análisis no solo predice futuros resultados, sino que también sugiere acciones específicas para alcanzar objetivos deseados.
- **Enfoques:** Combina técnicas de análisis predictivo con optimización matemática y simulación para recomendar decisiones.
- **Herramientas:** Plataformas avanzadas de analítica y BI como Tableau, Power BI, y herramientas de optimización como IBM ILOG CPLEX Optimization Studio.

➤ **Análisis Cognitivo y de IA**

Presente y Futuro:

- **Propósito:** La inteligencia artificial y el análisis cognitivo van más allá del análisis prescriptivo, utilizando tecnologías avanzadas como procesamiento de lenguaje natural (NLP) y aprendizaje profundo (deep learning) para entender e interactuar con los datos de manera más humana.
- **Enfoques:** Implementación de IA y algoritmos de deep learning para análisis avanzados, permitiendo sistemas autónomos que pueden aprender y adaptarse.
- **Herramientas:** Plataformas de IA como IBM Watson, Google AI, y Azure AI.

La evolución del proceso analítico ha pasado de simplemente describir datos históricos a utilizar la inteligencia artificial para predecir y recomendar acciones, adaptándose continuamente a los avances tecnológicos y las necesidades cambiantes del negocio. Cada etapa ha permitido a las organizaciones aprovechar los datos de manera más efectiva, mejorando la toma de decisiones y optimizando procesos.



Se utiliza la agregación y minería de datos para proporcionar una visión del pasado y responder **¿qué ha sucedido?**



Análisis descriptivo

Análisis predictivo



Se utilizan modelos estadísticos y técnicas de pronóstico para comprender el futuro y responder **¿qué podría pasar?**

Se utilizan algoritmos de optimización y simulación para asesorar sobre posibles resultados y responder **¿qué debemos hacer?**

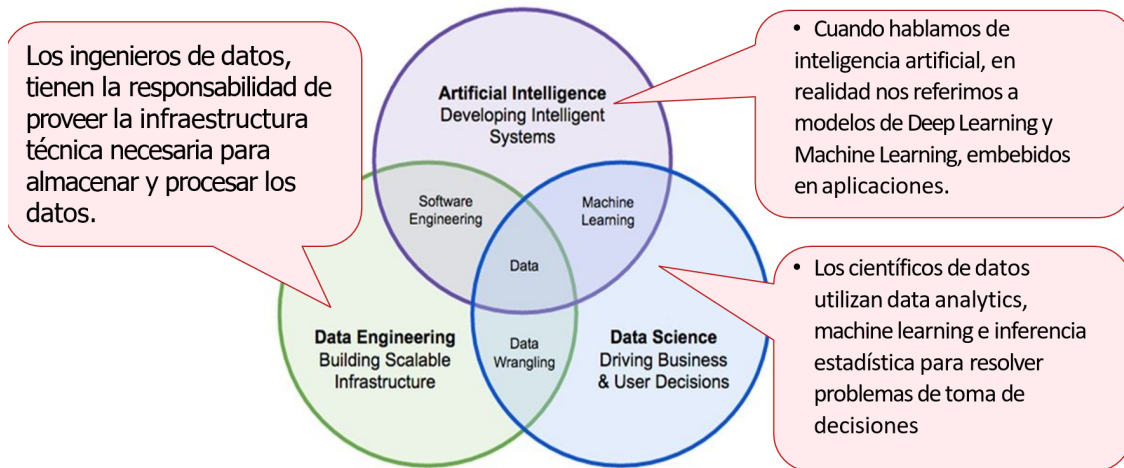


Análisis prescriptivo

¿Qué tipo de problemas resolvemos con Datos?



¿Cómo se relacionan estas disciplinas?



Jerarquía DIKW. Conceptos básicos: Dato e Información



La jerarquía del conocimiento también llamada jerarquía DIKW o PIRAMIDE DEL CONOCIMIENTO, podría ser definida como un conjunto de modelos para representar

las relaciones aparentemente estructurales entre DATOS, INFORMACION, CONOCIMIENTO, y en algunos casos SABIDURIA.

¿Qué es dato?

El dato se refiere a la representación simbólica de una entidad, por ejemplo, letras del alfabeto, números, puntos, dibujos, etc. Estos datos por sí solos no tienen valor semántico. Pero si se lo procesa apropiadamente, este provee información importante ayudando en la toma de decisiones.

Características

- ✓ Representación Simbólica
- ✓ No tienen sentido semántico
- ✓ No transmiten Mensaje
- ✓ Describen situaciones, hechos

¿Qué es información?

La información se refiere al conjunto de datos, que están organizados para transmitir un significado, con el propósito de reducir la incertidumbre e incrementar el conocimiento.

La Información favorece a la resolución de problemas puesto que permite una adecuada toma de decisiones.

Características

- ✓ Conjunto de datos procesados y organizados
- ✓ Tiene significado, transmite un mensaje
- ✓ Incrementa el conocimiento
- ✓ Facilita la toma de decisiones

¿Qué es Cultura Data Driven?

Características

Tomar decisiones en base a información.

- ✓ Generar conocimiento.
- ✓ Alcance a toda la organización.
- ✓ Democratización de los datos.
- ✓ Gobierno de Datos.
- ✓ Medición del riesgo y de activos intangibles



¿Por qué a las organizaciones se les dificulta ser Data Driven ?

Dificultades: Errores en el armado de los equipos de Datos

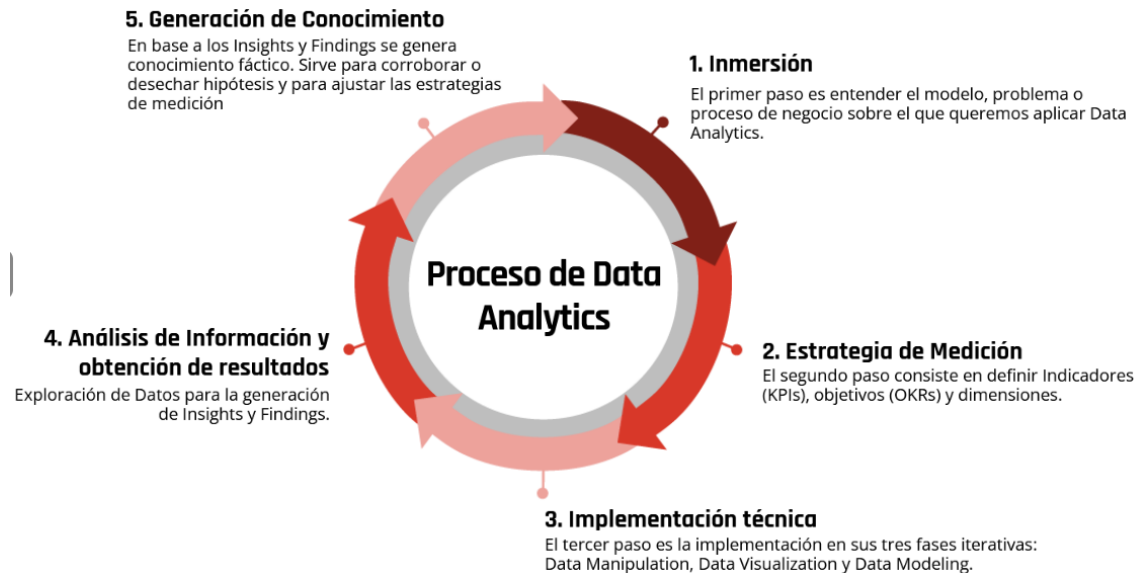
- ✓ Falta de capacidades y habilidades en el Análisis de Datos
- ✓ Sesgos
- ✓ Miedo al cambio
- ✓ Desconfianza en los datos y los procesos, para tomar decisiones.
- ✓ Problemas en la adopción de las aplicaciones de Analytics
- ✓ Interpretabilidad de los algoritmos

Para pensar!!!!

Cultura Data Driven

Según tu percepción ¿Tu organización es Data Driven?


3.3 Estrategia de medición: KPIs y OKRs



Estrategia de medición Data Analytics

Como veíamos en el Data Analytics Journey, uno de los pasos esenciales en nuestro rol de Data Analyst es **definir la estrategia de medición**. Pero ¿qué criterios se tienen en cuenta a la hora de definir un indicador? ¿Por qué será tan importante seleccionar indicadores dentro de cualquier organización?

Veamos lo que nos dice **William Thomson, físico y matemático británico**, quien acuña una frase que puede resumir muy bien la importancia de tener una buena estrategia de medición:



William Thomson

“Lo que no se define no se puede medir. Lo que no se mide no se puede mejorar. Lo que no se mejora se degrada siempre”.

Por su parte, John Doerr autor del famoso libro

[“Mide lo que importa. Cómo Google, Bono y la fundación Gates cambian el mundo con OKRS”](#), nos dice lo siguiente:



John Doerr

“No aprendemos de la experiencia: aprendemos reflexionando sobre la experiencia”.

Bonus Track

Para seguir profundizando en la importancia de una buena estrategia de medición, los invitamos a ver la siguiente charla TED de John Doerr sobre la importancia del uso de OKRs:

Charla TED de John Doerr sobre la importancia del uso de OKRs:

<https://www.youtube.com/watch?v=L4N1q4RNI9I&list=PLR-yDXgvjcM3CO9clZLDneGEcyaISp-9G>

Objetivos de Negocio

- ✓ KPIs
- ✓ Dimensiones
- ✓ Resultados

En el proceso analítico, el primer paso consiste en entender el modelo, problema o proceso de negocio sobre el que queremos aplicar Data Analytics. Una vez cumplido este primer paso, el segundo paso consistirá en definir la estrategia de medición que vamos a usar.

¿En qué consiste esta estrategia de medición?

En definir objetivos de negocio y resultados (OKRs), indicadores (KPIs) y dimensiones.



KPIs

¿Cómo podemos evaluar el éxito?

Una buena estrategia para hacerlo son los Key Performance Indicators

Características de los KPIS



En resumen, los KPIs tienen que informar, controlar, evaluar y por último ayudar a que se tomen decisiones.

Cada empresa tiene sus propios indicadores de gestión, dado que cada organización, cada industria y cada modelo de negocio tienen factores claves diferentes.

¿¿Que ejemplos se te ocurren?? Cantidad de viajes semanales en UBER. Cantidad de clicks en Mercadolibre

Otros ejemplos puedes encontrar en <http://kpilibrary.com/>

Dimensiones

Son variables cualitativas que nos permiten analizar las métricas (o indicadores), agruparlas, filtrarlas u ordenarlas.

Son variables del tipo:

- Texto: Categorías de productos, Segmentos de clientes, Sucursal.
- Booleans: Datos del tipo Sí/No, Verdadero/Falso, 0 o 1.
- Tiempo: Fecha, Año, Trimestre, Tiempo. (Son utilizadas con funciones conocidas como time intelligence)

Trabajo en equipo

Descarguen el dataset “Productos” en el que encontrarán las siguientes hojas:

1. Modelo de negocio: explica a qué se dedica la empresa dueña de los datos.
2. Descripción de los campos: diccionario con la definición de las columnas.
3. Productos Dataset: los datos propiamente dichos.
4. KPIS y Dimensiones: plantilla para Actividad 1.
5. OKRs: plantilla para Actividad 2.

Vamos a analizar la información de la hoja 3 del dataset “Productos”.

- A partir del dataset “Productos” vamos a definir una pregunta de negocio

Ejemplos de preguntas de negocio

- ✓ • ¿Qué productos pueden tener problemas de quiebre de inventario?
¿Qué cantidad de ventas perdemos por esa situación?
- ✓ • ¿Cuál es nuestro costo financiero por tener inventario que no es esencial o relevante para satisfacer a nuestros clientes?
- ✓ • ¿Es posible definir alguna estrategia con nuestros proveedores?

Trabajo en equipo - Consigna

A partir de la pregunta de negocio definida deberán:

- ✓ Responder ¿qué indicadores consideran que son más adecuados para responder esa pregunta de negocio? Definir métricas y dimensiones.
- ✓ Definir las fórmulas de cálculo para los indicadores definidos.
- ✓ Completar la definición según el siguiente diseño:

Medida/Indicador	Campo/fórmula	Unidad de medida	Dimensiones
KPI1	Columna 1 * Columna 4	Unidades	Dimensión 1 Dimensión 2
KPI2	Columna 3 / Columna 8	\$/unidad	Dimensión 2 Dimensión 3

Trabajo en equipo: presentación

- Cada grupo defina los siguientes roles:
 - 1 Project Manager (PM): responsable del cumplimiento de los tiempos, de facilitar la comunicación y hacer seguimiento del flujo de trabajo.
 - 3 a 5 Analistas: encargados de analizar los datos y definir las métricas y los objetivos por cada Key Result definido para el OKR.
 - 1 a 2 Storytellers: encargados de resumir y presentar la estrategia de medición y los objetivos planteados.

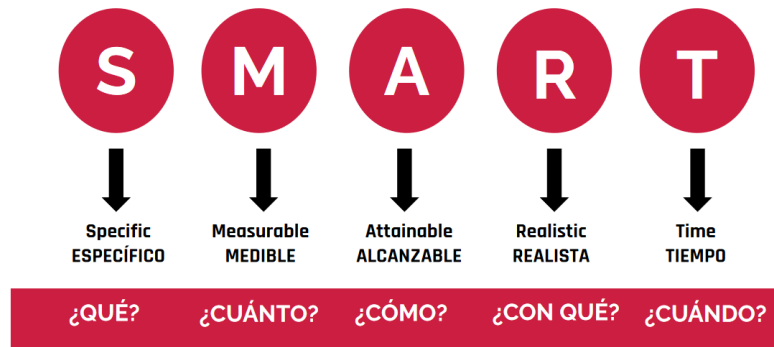
Actividad	Tiempo	Responsable
Distribución de roles	5 minutos	Equipo
Definición de Estrategia de Medición.	15 minutos	Equipo
Preparar presentación, justificación con datos.	15 minutos	Analistas, Presentadores
Presentación de resultados (en la puesta en común)	3 minutos (por grupo, se seleccionarán aleatoriamente)	Presentadores (storytellers)

Objetivos S.M.A.R.T

La metodología SMART para definir objetivos fue ideada por George T. Doran. Esta forma de definir objetivos ha demostrado ser la más eficaz en el entorno laboral ya que evita incertidumbres y ofrece toda la información necesaria para que puedan ser cumplidos con celeridad.

Surge a partir un artículo de 1981 de George T. Doran titulado "There's a S.M.A.R.T. way to write management's goals and objectives".

Objetivos S.M.A.R.T



OKRS

¿Qué son los OKRs?

Reciben su nombre por los términos en inglés de los términos objetivos y resultados clave: Objectives and Key Results.

Podemos definirlos como objetivos para lograr crecimiento y mejora en diferentes ámbitos personales y profesionales.

¿Cómo construir OKRs?

- ✓ **Objetivos:** Son descripciones cualitativas memorables de lo que queremos lograr. Deben ser cortos, inspiradores y atractivos. Un objetivo debe motivar y desafiar al equipo.
- ✓ **Resultados Clave:** Es el conjunto de métricas que miden el proceso hacia el objetivo. Cada objetivo debe tener un conjunto de 2 a 5 resultados clave.

Un objetivo bien planteado tiene que incluir qué queremos alcanzar y cómo vamos a medir su éxito. Doerr propone la siguiente fórmula para plantear buenos OKRs:

Voy a _____ y lo voy a medir con _____

(Objetivo)

(Set de resultados claves)

Cómo construir OKRs?

Pensemos en un ejemplo: supongamos que nuestro objetivo es crear una experiencia de cliente memorable.

¿Cómo podemos medir si estamos dando una experiencia "memorable"?

¿Qué resultados clave usaríamos?

Cómo podemos medir si estamos dando una experiencia “memorable”? ¿Qué resultados clave usaríamos?

Objetivo 1	Generar una excelente experiencia fuera y dentro del aula con un alto nivel de satisfacción de los alumnos en el 2do semestre 2020	Progreso	Cumplimiento Objetivo
			93%
KR1	Que el 100% de los clusters alcance el NSI objetivo	38%	
KR2	Alcanzar un NPS de 40pts	99%	
KR3	Reducir la baja Alumnos a menos del 5,5%	143%	

¿Qué diferencia hay entre los KPIs y los OKRs?

- Los Objetivos en OKRs son objetivos “motivadores y aspiracionales”
- Los Key Results son objetivos cuantitativos que se miden en base a un KPI específico.
- Un Objetivo en OKRs puede ser medido con varios KRs (de 2 a 5 es lo recomendado).
- Los KPIs son métricas (variables cuantitativas) que permiten medir el cumplimiento de un Key Result y, por lo tanto, de un Objective cuando utilizo OKRs.

En resumen, los OKRs:

- Deben tener resultados medibles.
- Deben ser ambiciosos
- Deben ser establecidos con el consentimiento de la persona que quedará con el OKR.
- Son el resultado de una acción o tarea.
- Mejoran el análisis de lo que se está haciendo.
- Deben ser simples, y se recomienda aplicar de 2 a 5 Key results.
- Deben ser públicos si se están usando en una organización.
- Se deben actualizar constantemente, para no perderlos de vista y llevarle un seguimiento rígido.

Diferencia entre SMART y OKRS

	S.M.A.R.T	OKRS
Específicos	SI	Sí y permite agrupaciones de resultados clave que son más representativos del éxito.
Medibles	SI	Sí. Los resultados clave siempre deben contener un nombre de métrica y una métrica objetivo y, por lo tanto, deben poder medirse.
Realizable	SI	Algunos resultados clave funcionan como de costumbre y se pueden lograr. Pero los resultados clave también pueden contener un alto grado de estiramiento.
Pertinente	SI	Los OKR son transparentes en toda la empresa, están alineados y, por lo tanto, deben ser muy relevantes.
Limitados en el tiempo	SI	Los OKR a menudo funcionan en períodos trimestrales y meses, pero pueden funcionar en cualquier período de tiempo.
Jerárquico	NO	Los OKR tienen una estructura jerárquica que ayuda a garantizar la alineación de arriba hacia abajo y de abajo hacia arriba.
Colaborativo	Posiblemente	Los OKR suelen ser colaborativos por diseño, es decir, se asignan propietarios y colaboradores porque su transparencia lo fomenta orgánicamente.

Trabajo en grupos

En base al resultado del práctico anterior y a las dimensiones definidas intentaremos definir los OKRS.

Responder: ¿qué Objective & Key Results le plantearían al responsable de Compras e Inventarios para el próximo trimestre?

- Recuerden que el objetivo deber ser motivador e inspirador. Usen los KPIs ya definidos para definir los KRs. Los objetivos de cada KRs deben ser consistentes con los datos del dataset.
- Completar la definición según el siguiente diseño:

Objetivo 1:	Aca Definimos el objetivo...recuerden...motivador, inspirador...Con un objetivo alcanza para esta actividad.. pero si quieren pueden definir más!	Progreso	Cumplimiento Objetivo
			Aca definimos como ponderamos los KRs..
KR1	Aca definimos el primer KR: recuerden definir su objetivo..	38%	
KR2	Aca definimos el segundo KR.....	99%	
KR3	Definimos un máximo de 5 KR por objetivo...	143%	

Actividad	Tiempo	Responsable
Definición de OKRs	10 minutos	Equipo
Preparar presentación, justificación con datos.	10 minutos	Analistas, Presentadores
Presentación de resultados (en la puesta en común)	3 minutos (por grupo, se seleccionarán aleatoriamente)	Presentadores (storytellers)

3.4 Implementación: Fases en Data Analytics

Como toda disciplina, Data Analytics cuenta con una metodología que consta de una serie de pasos que nos guían para realizar un análisis adecuado de los datos. Ya sabemos que, una vez entendido el problema que queremos resolver mediante la aplicación de Data Analytics, el paso a seguir es construir una buena estrategia de medición definiendo KPIs, OKRs y dimensiones.

El tercer paso en el Data Analytics Journey consiste en la implementación técnica del análisis de datos. Pero ¿cuáles son los pasos para aplicar Data Analytics y no morir en el intento? En el siguiente video vamos a explicar cuáles son los tres pasos para realizar un análisis de datos efectivo, cuál es el objetivo de cada etapa y los factores críticos que debemos tener en cuenta en cada etapa.



En resumen, las tres fases de Data Analytics son un proceso constante que transcurre de forma iterativa todo el tiempo y no en un orden secuencial.

Ahora que vimos la generalidad de los conceptos de Data Manipulation, Data Modeling y Data Visualization vamos ahora a profundizar y conocer en detalle cada uno de estos conceptos.

3.5 Data Manipulation, Data Visualization, Data Modeling

Data Manipulation

¿Qué entendemos por Data Manipulation? Llamamos Data Manipulation a las técnicas que nos permiten tener los datos listos para ser analizados. Esto es importante porque normalmente ocurre que los datos tienen datos faltantes, están escritos en distintos formatos, contienen errores, en fin. En esta etapa nuestro objetivo fundamental como Data Analyst es poder unificar y automatizar los datos con los que vamos a trabajar.

Data Visualization

¿Alguna vez se enfrentaron a una hoja de cálculo en Excel repleta de datos y no pudieron identificar ni una sola tendencia o un patrón común? Seguramente esa no tan grata experiencia permite entender cuan efectiva puede ser una buena visualización de datos.

Podemos definir de forma breve la visualización de datos como la representación gráfica de información y datos mediante el uso de distintos elementos visuales como cuadros, gráficos y mapas. Las herramientas de visualización de datos son importantes pues nos dan una forma accesible no solo de ver sino de comprender las tendencias, los valores atípicos y patrones comunes en los datos.

Ahora ¿por qué es importante una buena visualización? Las herramientas y buenas prácticas de visualización son fundamentales para analizar grandes cantidades de información y tomar decisiones basadas en datos. Además vale la pena destacar que somos una cultura está determinada por un componente visual: nos sentimos atraídos por los colores y patrones, por las imágenes en la publicidad, la televisión y películas. Desde esta perspectiva, **la visualización de datos es otra forma de producción visual que permite captar el interés de los usuarios para enfocar en el mensaje** pues, si como usuarios vemos el mensaje, lo interiorizamos rápidamente.

Bonus Track

Los invitamos a explorar los siguientes enlaces donde encontrarán información adicional complementaria sobre Data Visualization:

[Eager Eyes - Blog de Robert Kosara: contenidos sobre data visualization y visual storytelling.](#)

[FiveThirtyEight - Data: datasets e historias visuales con datos.](#)

[Flowingdata.com - Blog de Nathan Yau: la membresía da acceso a ejemplos premium pero hay ejemplos gratuitos disponibles.](#)

[The Functional Art - Blog de Alberto Cairo: una introducción a visualización y gráficos de información, con posts de consejos y ejemplos.](#)

[The Guardian Data Blog: datos relacionados a noticias.](#)

[PolicyViz: recursos varios sobre visualización de datos, ejemplos, comentarios de comunidad, etc.](#)

[VizWiz: Data visualization best practices, "tips and tricks" para Tableau Software.](#)

[Storytelling With Data: blog focalizado en una comunicación efectiva con datos. Contiene ejemplos y dialogos para la presentación de los datos.](#)

[Data Viz Project: sitio web que intenta presentar todas las visualizaciones de datos relevantes para que el usuario pueda encontrar la visualización correcta e inspirarse en cómo hacerlas.](#)

Data Modeling

Data Modeling es uno de los procesos clave en el análisis de datos. ¿En qué consiste? **En la representación de datos no solo para obtener la información que necesitamos sino para inferir escenarios futuros a partir de los datos que disponemos mediante la aplicación de técnicas de machine learning.** Para lograr el éxito en esta etapa se debe conseguir que las relaciones y los flujos de datos entre los diferentes elementos queden bien representadas.

3.6 Casos de Estudio

En el campo de Data Analytics, algunos casos de estudio de ejemplo muestran cómo diferentes empresas y organizaciones han utilizado el análisis de datos para resolver problemas específicos y mejorar sus operaciones:

Caso de Estudio 1: Mejora de la Experiencia del Cliente en una Cadena de Supermercados

Empresa: Walmart

Desafío: Walmart quería mejorar la experiencia del cliente en sus tiendas físicas y online.

Solución:

- **Recolección de Datos:** Se recolectaron datos de transacciones, comportamiento de compra, interacciones en redes sociales y encuestas de satisfacción.
- **Análisis de Datos:** Se utilizaron técnicas de análisis predictivo para identificar patrones en el comportamiento de los clientes.
- **Implementación:** Walmart personalizó sus promociones y mejoró la disposición de los productos en las tiendas.
- **Resultados:** Aumento en la satisfacción del cliente y en las ventas.

Caso de Estudio 2: Optimización de la Cadena de Suministro en una Empresa de Ropa

Empresa: Zara (Inditex)

Desafío: Zara necesitaba optimizar su cadena de suministro para reducir los tiempos de respuesta y ajustar mejor la oferta a la demanda.

Solución:

- **Recolección de Datos:** Datos de ventas, inventarios y producción en tiempo real.
- **Análisis de Datos:** Algoritmos de machine learning para predecir la demanda de productos específicos en diferentes tiendas.
- **Implementación:** Ajuste dinámico de la producción y distribución de productos basándose en las predicciones de demanda.
- **Resultados:** Reducción de inventarios sobrantes y faltantes, aumento en la rotación de productos y mejora en la satisfacción del cliente.

Caso de Estudio 3: Prevención del Fraude en una Institución Financiera

Empresa: PayPal

Desafío: PayPal necesitaba identificar y prevenir actividades fraudulentas en tiempo real.

Solución:

- **Recolección de Datos:** Datos transaccionales históricos y en tiempo real, junto con datos de comportamiento de usuarios.
- **Análisis de Datos:** Modelos de machine learning para detectar patrones de fraude y anomalías.
- **Implementación:** Sistema de monitoreo en tiempo real que alerta sobre transacciones sospechosas.
- **Resultados:** Disminución significativa en el fraude y mejora en la confianza de los clientes.

Caso de Estudio 4: Personalización de Contenidos en una Plataforma de Streaming

Empresa: Netflix

Desafío: Netflix quería mejorar la personalización de recomendaciones de contenido para aumentar el tiempo de visualización y la retención de usuarios.

Solución:

- **Recolección de Datos:** Datos de visualización de usuarios, calificaciones, búsquedas y preferencias.
- **Análisis de Datos:** Algoritmos de recomendación basados en machine learning que analizan el comportamiento del usuario y patrones de contenido.
- **Implementación:** Sistema de recomendaciones personalizado que se actualiza en tiempo real.
- **Resultados:** Aumento en el tiempo de visualización y en la satisfacción del usuario.

Caso de Estudio 5: Optimización de la Eficiencia Energética en una Empresa de Servicios Públicos

Empresa: General Electric (GE)

Desafío: GE quería optimizar el uso de energía en sus plantas de producción para reducir costos y mejorar la eficiencia.

Solución:

- **Recolección de Datos:** Sensores IoT en máquinas y equipos para recolectar datos en tiempo real sobre el uso de energía y rendimiento.
- **Análisis de Datos:** Modelos de análisis predictivo para identificar oportunidades de ahorro y optimización.
- **Implementación:** Ajustes operativos basados en las recomendaciones del análisis de datos.
- **Resultados:** Reducción en el consumo de energía y en los costos operativos, aumento en la eficiencia de la producción.

Caso de Estudio 6: Predicción de Mantenimiento en una Empresa de Transporte

Empresa: Delta Airlines

Desafío: Delta Airlines quería reducir el tiempo de inactividad de sus aviones debido a mantenimiento no planificado.

Solución:

- **Recolección de Datos:** Datos de sensores de aviones, registros de mantenimiento y datos operativos.
- **Análisis de Datos:** Algoritmos de machine learning para predecir fallos y necesidades de mantenimiento antes de que ocurran.
- **Implementación:** Sistema de mantenimiento predictivo que programa revisiones y reparaciones de manera proactiva.
- **Resultados:** Reducción en los tiempos de inactividad no planificados y en los costos de mantenimiento, mejora en la puntualidad de los vuelos.

Estos casos de estudio demuestran cómo el análisis de datos puede ser aplicado en diferentes industrias para resolver problemas complejos, mejorar la eficiencia, personalizar la experiencia del cliente y tomar decisiones informadas.

Herramientas de data analytics



Herramientas de Data Analyti



+ a b | e a u[®]